

Avance 7. Resumen ejecutivo actualizado

Plataforma MLOps para Pricing Intelligence en Azure

Equipo 46 | Resumen para tomadores de decisión | Arquitectura vigente

Enfoque actualizado: reentrenar por evidencia, no por calendario

Propósito	Concentrar las conclusiones esenciales del proyecto, su costo-beneficio, riesgos y recomendación ejecutiva.
Tesis ejecutiva	El valor principal no es ahorrar GPU; es gobernar el ciclo de vida del modelo HB-SVI con evidencia operacional/pre-model de drift.
Solución vigente	MVP MLOps en Azure: Azure ML batch endpoint → pipeline component/job → Storage MLOps → handoff y registros audita- bles.
Resultado clave	Con seis meses posteriores de datos AUTH, el drift no justificó un reentrenamiento completo del HB-SVI; sí justificó monitoreo ope- racional, scoring/update y trazabilidad.
Decisión recomendada	Continuar en staging/validation, estabilizar el batch endpoint y completar model health, auditoría productiva y gobierno antes de producción.

Decisión ejecutiva recomendada

Decisión solicitada	Aprobar la continuidad del MVP hacia validation, manteniendo la política de retraining basada en evidencia y operando el flujo desde el batch pipeline endpoint administrado en Azure ML.
Criterio de avance	No promover todavía a producción final. Primero estabilizar el pi- peline versionado, formalizar thresholds con negocio y definir reglas de model health, retraining, auditoría productiva y rollback.

Mensaje central: el proyecto responde “¿el modelo ya envejeció lo suficiente como para volver a entre- narlo?”. La respuesta actual es: no todavía; se conserva el modelo y se continúa monitoreando. Esta versión actualiza la arquitectura vigente; el documento histórico queda preservado por separado.

1. Resumen ejecutivo

El proyecto aborda una necesidad crítica de Pricing Intelligence: pasar de corridas analíticas aisladas a una operación trazable, auditable y repetible. En un entorno B2B donde cambian productos, distribuidores, segmentos, costos, precios y cantidades, no basta con generar una recomendación; también se necesita justificar cuándo mantenerla, cuándo actualizarla y cuándo reentrenar el modelo que alimenta la lógica de pricing.

La solución implementada corresponde a una base MLOps en Azure operada actualmente desde **pricing-mlops**. El runtime vigente usa un Azure ML batch pipeline endpoint como punto de entrada administrado, un pipeline component versionado como capa de ejecución, Storage MLOps como repositorio de evidencia versionada y registros auditables como contrato de salida. No hay Azure Function intermedia operando el flujo ni Azure SQL audit desplegado como capa productiva.

El enfoque analítico de pricing se basa en un modelo HB-SVI que estima elasticidades. Esas elasticidades alimentan una S-curve de demanda y posteriormente una optimización de revenue/profit para producir recomendaciones de precio. Por tanto, el precio recomendado no sale directamente del modelo, sino de una cadena de decisión: elasticidad $\rightarrow$ demanda estimada $\rightarrow$ optimización $\rightarrow$ reglas y validaciones.

La conclusión ejecutiva más importante es que el principal valor del proyecto no está en reducir el costo directo de GPU por corrida. Si una corrida de entrenamiento dura poco, el ahorro de cómputo puede ser marginal y discutible. El valor real está en establecer una política MLOps para decidir cuándo reentrenar el HB-SVI con base en evidencia. En lugar de reentrenar mensualmente por calendario, el sistema evalúa si los datos recientes presentan cambios suficientes frente al baseline.

Con seis meses posteriores de datos AUTH, el análisis de drift mostró que no existe una señal crítica suficiente para justificar un reentrenamiento completo del HB-SVI. La decisión correcta es conservar el modelo actual, ejecutar scoring/update para nuevos combos cuando aplique, registrar la evidencia y continuar monitoreando. En la arquitectura vigente, esa capacidad vive como monitoreo operacional/pre-model dentro del pipeline de Azure ML; la medición completa de model health HB-SVI/S-curve sigue siendo la siguiente capa de madurez.




Figura 1: Flujo de generación de la recomendación de pricing.

2. Problema de negocio

El problema no es solamente calcular precios recomendados; es operar el ciclo de vida de esas recomendaciones y del modelo que las habilita. Sin una plataforma MLOps, las decisiones de retraining tienden a hacerse por rutina, intuición o calendario, lo que puede introducir cambios innecesarios y aumentar la carga de validación.

- Riesgo de reentrenar por calendario sin evidencia de degradación.

- Riesgo de cambiar un modelo estable y generar nuevas versiones innecesarias.
- Dificultad para auditar qué datos, código y configuración generaron una recomendación.
- Dificultad para distinguir entre drift de datos, falta de cobertura, drift de precio y degradación real del componente predictivo.
- Sobrecarga operativa para revisar manualmente outputs y justificar decisiones ante negocio.

3. Hallazgos principales del análisis exploratorio y de preparación

Avance	Hallazgo	Implicación para la solución
Avance 1 - EDA	Los datos de pricing tienen distribuciones long-tail y nulos estructurales en ciertas variables de costo.	La plataforma debe separar calidad real de comportamiento normal del negocio.
Avance 2 - Feature Engineering	Se consolidó una tabla de features de 8,314 filas con validaciones de consistencia y señales como P20 ajustado, near extreme y rangos P20-P85.	Sirve como base para baseline, monitoreo y contratos de datos.
Avance 3 - Baseline	Se congeló un baseline de 8,314 recomendaciones y 6,982 KPN, con semáforo Green 61.58 %, Yellow 38.42 % y Red 0 %.	El sistema ya tiene referencia contra la cual medir cambios futuros.
Avance 4 - Drift AUTH real	Se compararon seis meses posteriores de historia AUTH contra el baseline; aparecieron 1,754 combos nuevos y señales de coverage/history drift.	Se justifica scoring/update y monitoreo, no reentrenamiento completo por calendario.
Posterior a Avance 6	Se integró la lógica de drift operacional en el pipeline administrado por Azure ML batch endpoint.	El diseño se convirtió en una capacidad operativa trazable sin Function intermedia y con auditoría pendiente de conexión SQL productiva.

4. Modelo y razones del enfoque elegido

El enfoque elegido no busca que un modelo de caja negra entregue directamente el precio final. Se eligió una cadena explicable y alineada al negocio:

- HB-SVI estima elasticidad por producto/segmento, capturando incertidumbre y heterogeneidad.
- La elasticidad alimenta una S-curve para estimar demanda ante cambios de precio.
- La optimización de revenue/profit genera una recomendación de precio.
- Las reglas de negocio, bandas P20-P85, cobertura y drift controlan si la recomendación sigue siendo válida.

Esto permite que el monitoreo no se limite a “subió o bajó el precio”, sino que pueda evolucionar hacia preguntas más completas: ¿la elasticidad sigue explicando la demanda?, ¿la S-curve sigue calibrada?, ¿el nuevo

mix de productos requiere actualización?, ¿hay suficientes señales para reentrenar? En el estado vigente, esas preguntas completas siguen en roadmap; el pipeline implementado cubre señales operacionales/pre-model.

Modelo final seleccionado y razón de elección

Elemento	Decisión	Razón ejecutiva
Modelo base	HB-SVI para estimar elasticidad	Permite capturar incertidumbre y heterogeneidad entre productos, segmentos y regiones, en lugar de depender de una regla fija.
Capa económica	S-curve de demanda	Convierte elasticidad en una relación interpretable entre precio y cantidad esperada.
Capa de decisión	Optimización de revenue/profit con reglas de negocio	Conecta el modelo con un objetivo económico y con restricciones comerciales como bandas, costos y cobertura.
Capa MLOps	Drift-based retraining operacional/pre-model	El modelo no se reentrena por calendario; se conserva o actualiza con base en evidencia medible, con model health completo como siguiente capa.

5. Solución MLOps propuesta e implementada




Figura 2: Arquitectura ejecutiva vigente de la solución en Azure.

La solución opera como un MLOps foundation. No es aún un ciclo MLOps productivo completo, pero ya contiene los bloques esenciales para ejecutar, monitorear y conservar evidencia:

- **pricing-mlops-platform** provisiona foundation y workload: resource groups, Key Vault, Log Analytics, Application Insights, Storage funcional, Storage runtime de Azure ML, Azure ML Workspace, Managed Identity para jobs, RBAC y compute `cpu-cluster`.
- **pricing-mlops** registra componentes, publica el pipeline component, despliega/invoca el batch endpoint y publica artefactos funcionales en Storage.
- El endpoint vigente es un Azure ML batch pipeline endpoint; no hay Azure Function como runtime operacional intermedio.
- El pipeline vigente es `pricing_mlops_auth_monitoring_pipeline:0.1.18`.

- Storage MLOps conserva raw-masked, curated, baseline, runs, snapshots, drift-logs, reports y artifacts.
- La auditoría productiva en Azure SQL no está desplegada; el repo funcional genera registros auditables y contratos de salida antes de conectar una base SQL real.
- GitHub Actions registra componentes y actualiza el batch endpoint, pero no opera un ambiente productivo.

Elemento vigente	Estado operativo
Batch endpoint	pricing-auth-monitoring/blue apunta al pipeline component de AUTH monitoring.
Pipeline versionado	pricing_mlops_auth_monitoring_pipeline:0.1.18.
Pasos del pipeline	validate_prepare, feature_engineering, prepare_current_auth_history, build_monitoring_inputs, calculate_recommendation_validity, calculate_auth_history_drift, calculate_operational_decision, simulate_operational_handoff, publish_outputs, notify_operational_decision.
Ambientes	staging y validation habilitan Azure ML; no existe prod en IaC, parámetros ni workflows.
Límites actuales	Sin Private Endpoints, ADF operativo, Azure Functions operativas, SQL audit activo ni endpoints online.

Estado actualizado: el drift ya no debe describirse solo como propuesta. Está integrado como monitoreo operacional/pre-model dentro del flujo Azure ML. La siguiente capa será model health del HB-SVI/S-curve y una auditoría productiva si negocio lo requiere.

6. Decisión MLOps: reentrenar por evidencia, no por calendario

Esta es la sección más importante del resumen ejecutivo. El argumento no debe centrarse en que se ahorra GPU, sino en que se evita tomar decisiones de entrenamiento sin evidencia. El ahorro de cómputo queda como beneficio secundario.




Figura 3: Política MLOps de reentrenamiento basada en drift.

Pilar	Qué demuestra	Beneficio	Estado
Gobernanza del modelo	Hay criterios para decidir cuándo entrenar.	Evita decisiones por calendario o intuición.	Implementado a nivel de drift operacional/pre-model.
Estabilidad del modelo	Seis meses posteriores no detonaron señal suficiente para retraining completo.	Se mantiene un modelo estable.	Evidencia disponible en Avance 4.
Reducción de retraining innecesario	El reentrenamiento se reserva para casos con señales acumuladas.	Menor carga de validación y menor riesgo de cambio innecesario.	Propuesto/operable.
Trazabilidad	Cada decisión queda registrada con métricas, logs, snapshots y contratos auditables.	Mejor auditoría y explicación ante negocio.	Implementado en Storage; SQL productivo pendiente.
Escalabilidad MLOps	El monitoreo corre antes del retraining desde un batch endpoint administrado.	Permite automatizar gating de modelos.	Base implementada; madurez futura.

7. Resultados de drift y lectura ejecutiva

Señal	Resultado observado	Lectura ejecutiva	Decisión
Cobertura	1,754 combos nuevos; 17.42 %.	Hay nuevas combinaciones no cubiertas por el baseline.	Scoring/update, no retrain global.
AUTH history drift	Red.	La historia reciente cambió en composición o comportamiento.	Revisar segmentos y monitorear persistencia.
Price drift	Yellow.	Cambio moderado de precios.	No justifica HB-SVI retraining por sí solo.
Recommendation validity	Mayoría Watch; Red y Yellow acotados.	No hay razón para detener todo el flujo.	Priorizar revisión por revenue e impacto.
Impacto revenue	Red 1.16 %; Yellow 7.26 %.	El impacto crítico es acotado.	Revisión focalizada.
Reentrenamiento HB-SVI	No requerido por price drift alone.	El modelo no ha envejecido lo suficiente para retrain completo.	Mantener modelo y seguir monitoreando.

La conclusión es madura: el sistema no dice “nunca reentrenar”, sino “reentrenar cuando exista evidencia suficiente”. Esto reduce riesgo, no solamente costo.

8. Análisis costo-beneficio actualizado

El beneficio principal es control del ciclo de vida del modelo. El ahorro de GPU se vuelve relevante cuando el proceso actual de negocio reentrena el modelo mensualmente en una NVIDIA A10. En ese caso, el monitoreo de drift convierte el gasto de GPU de un costo fijo por calendario a una decisión condicionada por evidencia. El ahorro más sólido combina cómputo evitado, menor carga de validación y menor riesgo de cambiar un modelo estable sin necesidad.

Beneficio	Descripción	Indicador razonable	Prioridad
Gobernanza de modelo	Decidir retraining con métricas y baseline.	Política drift-based retraining documentada.	Alta
Estabilidad operativa	Evitar cambiar modelos estables sin necesidad.	Con 6 meses posteriores no se justificó retrain completo.	Alta
Trazabilidad	Registrar datos, código, outputs y decisión.	run logs, snapshots, drift logs, handoff y registros auditable; SQL productivo pendiente.	Alta
Ahorro operativo	Menos validaciones/retrabajo por entrenamientos innecesarios.	Horas de revisión evitadas por ciclo.	Media-alta
Ahorro de cómputo	Menos uso de GPU A10 cuando no hay señal de retrain.	Evitar retraining mensual cuando drift no justifica nueva versión.	Alta
Escalabilidad	El monitoreo puede automatizarse antes del retraining.	Gating previo a entrenamiento.	Alta

8.1. Impacto de evitar retraining mensual en GPU A10

El dato operativo de referencia es que, en la empresa, el modelo se entrena cada mes en una GPU NVIDIA A10. Para estimar el orden de magnitud en cloud, la Azure Retail Prices API reporta `Standard_NV36ads_A10_v5` en `eastus2` a USD 3.20 por hora. En contraste, el monitoreo actual corre en `cpu-cluster` con `STANDARD_DS2_V2`, aproximadamente USD 0.114 por hora. Por eso, una corrida de drift cuesta centavos, mientras que un retraining A10 puede costar decenas o cientos de dólares según duración.

Duración del retraining mensual	Costo por retrain A10	Costo anual por calendario	Lectura ejecutiva
4 horas	USD 12.80	USD 153.60	Ahorro directo moderado; sigue evitando validación innecesaria.
8 horas	USD 25.60	USD 307.20	Ya hay ahorro visible si varios meses no requieren retraining.
24 horas	USD 76.80	USD 921.60	El gating por drift puede evitar casi mil dólares anuales por modelo.
48 horas	USD 153.60	USD 1,843.20	El valor económico se vuelve material, además de liberar capacidad GPU.

Si la NVIDIA A10 es on-premise o ya está asignada por contrato interno, el ahorro puede no aparecer como reducción directa de factura cloud. Aun así, se conserva como costo de oportunidad: horas GPU liberadas, menor retrabajo de validación y menor riesgo de introducir una versión nueva sin evidencia.

Nota de interpretación de riesgos

El drift implementado monitorea cambios operativos en datos, cobertura, precio e historia AUTH. No debe interpretarse como medición completa de degradación predictiva del HB-SVI. La siguiente capa de MLOps debe comparar demanda estimada por la S-curve contra demanda real y evaluar si las elasticidades siguen explicando la historia nueva.

8.2. Costos por fase CRISP-ML

Fase	Costo principal	Rango estimado MVP	Justificación
Business/Data Understanding	Alineación y EDA.	Bajo-medio	Principalmente horas de equipo.
Data Preparation	Masking, features, baseline.	Medio	Trabajo analítico y storage bajo.
Modeling	HB-SVI y lógica de pricing.	Medio-alto	Fase más costosa en tiempo técnico.
Evaluation	Baseline, drift, validaciones.	Medio	Permite gobernar retraining.
Deployment	Azure ML batch endpoint, pipeline component, Storage MLOps e IaC de plataforma.	Medio	Infra administrada/bajo demanda sin Function intermedia.
Monitoring	Drift operacional/pre-model periódico.	Bajo recurrente	Evita retraining fijo y revisión innecesaria.

9. Riesgos y desafíos

Categoría	Riesgo	Impacto	Mitigación
Datos	Nuevos combos sin baseline.	Menor cobertura de recomendaciones.	Scoring/update y fallback policy.
Datos	Drift de composición mal interpretado.	Reentrenamiento innecesario.	Separar coverage drift, price drift y model health.
Prueba y confianza	No medir aún degradación predictiva completa del HB-SVI.	Decisiones incompletas de retraining.	Agregar demanda estimada vs real y calibración S-curve.
Prueba y confianza	Red entendido como retrain automático.	Costos y riesgo de cambio innecesario.	Revisión negocio/técnica antes de reentrenar.
Ataques/seguridad	Exposición de datos sensibles.	Riesgo de cumplimiento.	raw-unmasked solo en data-lab; RBAC; no account keys.
Cumplimiento	Poca evidencia histórica o auditoría consultable incompleta.	Difícil auditar decisiones.	Storage versionado, handoff y registros auditables; conectar SQL productivo si negocio lo requiere.
Operación	Promover a producción antes de madurez.	Riesgo técnico y reputacional.	Mantener staging/validation, sin prod, y completar roadmap.
Operación	Reintroducir orquestación fuera del endpoint sin necesidad clara.	Doble ownership y mayor complejidad.	Mantener el Azure ML batch endpoint como ruta operacional única.

10. Qué falta para MLOps completo




Figura 4: Madurez MLOps: base actual y capas faltantes.

La solución actual sí es MLOps, pero como foundation/MVP. Todavía faltan capas para un MLOps completo de producción:

- Model health: comparar demanda estimada por S-curve contra demanda real nueva.
- Elasticity health: analizar si las elasticidades HB-SVI siguen explicando el comportamiento reciente.
- Champion/challenger: comparar versiones del modelo y decidir cuál es mejor.
- Model registry: versionar modelos, artefactos, métricas y estado de promoción.
- Promotion/rollback: mover modelos entre ambientes y revertir si una versión falla.
- Retraining governance: definir umbrales y aprobación para recalibrar o reentrenar.
- Auditoría productiva: conectar SQL real para logs, drift y snapshots sólo si aparece un requisito de consulta/auditoría que lo justifique.
- Notificación externa o dashboard operativo: usar el payload estable de notificación como contrato de integración.
- Hardening enterprise: Private Endpoints, validation estable y eventual prod.

11. Conclusión ejecutiva

- El proyecto no debe venderse principalmente como ahorro de GPU. Ese beneficio existe, pero es secundario y puede ser debatible si las corridas son cortas.
- El valor principal es la decisión MLOps: reentrenar por evidencia, no por calendario.
- El drift permitió responder si el modelo ya envejeció lo suficiente para volver a entrenarlo. La respuesta actual es: no hay evidencia suficiente para reentrenar el HB-SVI completo; sí hay señales operativas que justifican scoring/update y vigilancia.
- La integración posterior del drift en Azure fortalece la solución porque convierte la propuesta en una capacidad operativa desde un Azure ML batch endpoint.
- La recomendación es continuar en staging/validation, consolidar el monitoreo de drift operacional/pre-model y agregar model health, auditoría productiva y gobierno antes de producción completa.

Frase final sugerida: El principal valor del proyecto no está en reducir el costo directo de GPU por corrida, sino en establecer una política MLOps para decidir cuándo reentrenar el modelo HB-SVI con base en evidencia.

Cierre para comité ejecutivo

Pregunta ejecutiva	Respuesta del proyecto
¿El modelo debe reentrenarse solo porque pasó el mes?	No. El proyecto propone reentrenar por evidencia de drift y, cuando exista la capa completa, model health; no por calendario.
¿Los seis meses posteriores justifican reentrenamiento completo?	No hay evidencia suficiente para reentrenar el HB-SVI completo solo por drift de precio/modelo.
¿Qué sí se debe hacer?	Ejecutar scoring/update para nuevos combos desde el batch endpoint, monitorear cobertura y revisar señales Yellow/Red con negocio.
¿Qué falta para MLOps completo?	Model health, demanda estimada vs real, champion/challenger, model registry, promoción, rollback, auditoría productiva y gobierno formal de retraining.

Anexo. Frase ejecutiva para presentación

El proyecto responde una pregunta crítica para Pricing Intelligence: ¿el modelo ya envejeció lo suficiente como para reentrenarlo? Con seis meses de datos posteriores, el monitoreo operacional/pre-model de drift mostró que no existe señal suficiente para un reentrenamiento completo del HB-SVI. Por ello, la decisión correcta es conservar el modelo, ejecutar scoring/update para nuevas combinaciones desde el batch endpoint y continuar monitoreando. Esto convierte el retraining en una decisión gobernada por evidencia y no por calendario.